

Universidad de la República — Facultad de Ingeniería
Introducción a la Ciencia de Datos — 2026

Tarea 1

*Análisis exploratorio de un corpus de noticias
(subconjunto de All the News 2.1 — Component One)*

Integrantes

Gustavo Tomsic — C.I.: 4.699.653-0

Sebastián Díaz — C.I. 4.942.056-6

Fecha de entrega: 13 de mayo de 2026

Índice

1. Parte 1 — Cargado y Limpieza de Datos

- A. Exploración de Datos
- B. Visualización temporal
- C. Limpieza de texto y conteo de palabras
- D. Elección de campos de texto
- E. Pistas que identifican al medio
- F. Restricción por sección o período

2. Parte 2 — Conteo de Palabras y Visualizaciones

- A. Palabras más frecuentes por medio
- B. Medios con mayor cantidad de palabras
- C. Matriz de menciones entre medios
- D. Preguntas propuestas

Parte 1: Cargado y Limpieza de Datos

A. Exploración de Datos

Analice el contenido del DataFrame. Reporte si existen datos faltantes en algún campo, o cualquier otro problema de calidad de datos que encuentre.

En particular, analice la cantidad de artículos por medio de prensa, y a partir de este punto trabaje con los **cinco medios con mayor cantidad de artículos**.

Datos faltantes por columna:

	faltantes	porcentaje
author	11405	37.75
section	10232	33.87
article	1176	3.89
url	141	0.47
publication	141	0.47
idx	0	0.00
article_idx	0	0.00
date	0	0.00
year	0	0.00
month	0	0.00
day	0	0.00
title	0	0.00

Filas duplicadas completas: 0

Filas con combinación de título y cuerpo duplicado: 237

```

publication
Reuters          9431
The New York Times 2840
CNBC             2623
The Hill         2349
People           1528
CNN              1446
Refinery 29      1236
Vice             1154
Mashable         1045
Business Insider  660
The Verge        594
TechCrunch       568
TMZ              552
Vox              549
Axios            538
Politico         518
Washington Post  468
Buzzfeed News    376
Gizmodo          329
Economist        303
Wired            231
Fox News         227
Vice News        187
New Republic     145
Hyperallergic    123
New Yorker        52
Name: count, dtype: int64

Top 5 medios:
['Reuters', 'The New York Times', 'CNBC', 'The Hill', 'People']
Filas en df_top_5: 18771

```

Observaciones sobre calidad de datos:

El dataset contiene 30.213 artículos distribuidos en 26 medios de prensa. No hay filas completamente duplicadas, pero sí 237 artículos que comparten título y cuerpo con al menos otro registro, lo que indica que algunos artículos fueron indexados más de una vez.

En cuanto a datos faltantes, los campos más afectados son:

- **author (37,75% faltante):** es el campo con mayor ausencia. Puede deberse a que algunos medios no incluyen firma en todos sus artículos o a problemas en la recolección.
- **section (33,87% faltante):** más de un tercio de los artículos no tienen sección informada. Esto es especialmente marcado: ya en `df.head()` se observan filas con `NaN` en este campo.
- **article (3,89% faltante):** 1.176 artículos no tienen cuerpo de texto. Representan una minoría, pero son inutilizables para análisis de contenido.

- **url y publication (0,47% faltante):** ambos campos tienen exactamente 141 valores ausentes, lo que sugiere que corresponden a las mismas filas con información de origen incompleta.


Adicionalmente, `df.info()` muestra `year`, `month` y `day` como tipo `str`, pero `df.head()` muestra valores como `2.0` o `8.0`, lo que indica que los datos numéricos fueron almacenados como texto con formato inconsistente. El campo `date` también presenta formatos mixtos (por ejemplo, `"2018-02-02"` y `"2018-12-27 19:20:08"`), lo que requiere manejo especial al parsear fechas.

Los cinco medios con mayor cantidad de artículos son Reuters (9.431), The New York Times (2.840), CNBC (2.623), The Hill (2.349) y People (1.528), que suman 18.771 artículos en total. Reuters domina claramente con más del triple de artículos que el segundo medio.

B. Visualización temporal

Genere una gráfica que permita visualizar los artículos de los cinco medios a lo largo del tiempo, con alguna escala temporal adecuada.

Comente si se identifican momentos de mayor actividad o patrones temporales en la cobertura.



Medios incluidos en la gráfica: ['CNBC', 'People', 'Reuters', 'The Hill', 'The New York Times']

Observaciones sobre la distribución temporal:

El dataset cubre el período enero 2016 – abril 2020, con cobertura relativamente pareja en 2016–2019 y una caída notable en 2020.

Patrones destacados por medio:

- **Reuters** domina en volumen en todos los años y registra su pico mensual en marzo 2020, probablemente asociado al inicio de la cobertura de la pandemia de COVID-19.
- **CNBC** muestra un crecimiento sostenido entre 2016 a 2019, con su pico mensual en octubre 2019.
- **The New York Times** tiene su pico mensual en marzo 2016.
- **The Hill** mantiene una producción relativamente estable a lo largo de todo el período, con pico en marzo 2018.
- **People** tiene cobertura consistente entre 2016 y 2019, pero no registra artículos en 2020, lo que sugiere que el muestreo del dataset no incluyó artículos de ese medio para ese año.

En líneas generales no se identifican estacionalidades claras, pero sí picos puntuales que coinciden con eventos de alta cobertura mediática como la crisis sanitaria.

C. Limpieza de texto y conteo de palabras

Se provee la función `clean_text(...)` que realiza parte de la normalización del texto.

Complete la función agregando signos de puntuación faltantes y cualquier otra normalización que considere oportuna.

Compruebe el resultado observando el contenido del DataFrame procesado.

Comente todas las transformaciones que haya agregado y justifique.

	publication	article
\		
0	Reuters	Feb 2 (Reuters) – Teva Pharmaceutical Industri...
1	CNBC	The head of the Centers for Medicare and Medic...
2	The Hill	Benchmark, the venture capital firm that helpe...
5	CNBC	(Updates with new first paragraph, adds backgr...
6	Reuters	TORONTO, Dec 4 (Reuters) – Bank of Montreal on...
8	The New York Times	Calculator Sure, if you choose the right place...
9	The New York Times	BOGOTÁ, Colombia – Colombia is investigating a...
11	The Hill	Virginia Gov. Terry McAuliffe (D) included a d...
12	CNBC	Italy's Finance Minister, Pier Carlo Padoan, h...
13	The Hill	Former Starbucks CEO Howard Schultz has recrui...


```

CleanText
0  feb 2 reuters teva pharmaceutical industries l...
1  the head of the centers for medicare and medic...
2  benchmark the venture capital firm that helped...
5  updates with new first paragraph adds backgrou...
6  toronto dec 4 reuters bank of montreal on tues...
8  calculator sure if you choose the right place ...
9  bogotá colombia colombia is investigating a po...
11 virginia gov terry mcauliffe d included a dig ...
12 italy s finance minister pier carlo padoan has...
13 former starbucks ceo howard schultz has recrui...

```

Transformaciones aplicadas en `clean_text` y justificación:

1. Relleno de valores faltantes (`fillna("")`) Evita errores en las operaciones de texto al procesar filas sin cuerpo de artículo. Esto nos evita tener que trabajar con objetos nan y strings a la misma vez sobre la columna.

2. Reemplazo de signos de puntuación por espacio Se reemplazan por espacio (en lugar de cadena vacía) para evitar que palabras adyacentes a puntuación queden pegadas. Por ejemplo, `"economía-política"` → `"economía política"` en lugar de `"economíapolítica"`. Fuimos agregando a medida que observábamos el resultado debajo y de nuestra intuición de que caracteres comunes podían llegar a aparecer. Para ser exhaustivo en el filtrado de la cadena de caracteres podríamos habernos asegurado de que los caracteres pertenezcan únicamente a la tabla ASCII.

3. Colapso de espacios múltiples Después de reemplazar puntuación por espacios, pueden quedar varios espacios consecutivos. Este paso los reduce a uno solo y elimina espacios al inicio y fin, dejando el texto listo para tokenizar con `.split()`.

D. Elección de campos de texto

Discuta si conviene trabajar con:

- sólo el cuerpo del artículo,

- sólo el título,
- o una combinación de ambos.

Justifique brevemente su decisión.

Decisión: conviene usar **principalmente el cuerpo del artículo** (`article`), y en la práctica del notebook ya se limpia esa columna.

Por qué el cuerpo: tiene mucho más texto que el título, así que refleja mejor el vocabulario y el estilo de cada medio.

Por qué no solo el título: el título es muy corto y depende mucho del tema del día; dos medios distintos pueden poner títulos parecidos sobre la misma noticia.

Cuándo combinar título + cuerpo: tiene sentido si queremos no perder información cuando falta parte del artículo (en el dataset hay filas sin `article`) o si el título aporta un matiz que no está en el primer párrafo. En ese caso se puede armar un solo texto, por ejemplo `title + " " + article` , y aplicar la misma limpieza.

E. Pistas que identifican al medio de prensa

Analice si en el texto aparecen pistas que identifiquen de manera directa al medio de prensa (nombres del medio, URLs, firmas, nombres de secciones, plantillas repetidas, etc.).

En caso de encontrarlas, comente si considera conveniente eliminarlas o reducir su impacto, y justifique su decisión.

	medio_mencionado	articulos_que_lo_mencionan
0	Reuters	9299
1	The New York Times	722
2	CNBC	961
3	The Hill	2392
4	People	5938

Ejemplos para Reuters

	publication	CleanText	title	url
0	Reuters	feb 2 reuters teva pharmaceutical industries l...	BRIEF-Teva Says Fremanezumab Marketing Authori...	https://www.reuters.com/article/brie-teva-say
6	Reuters	toronto dec 4 reuters bank of montreal on tues...	Bank of Montreal's quarterly earnings beat mar...	https://www.reuters.com/article/bm-results/ba
15	Reuters	houston reuters an outage on a major pipeline ...	Crude market takes U.S. Seaway pipeline outage...	http://www.reuters.com/article/u-pipeline-ope

Ejemplos para The New York Times

	publication	CleanText	title	url
8	The New York Times	calculator sure if you choose the right place ...	Are Beach House Rentals Profitable?	https://www.nytimes.com/2019/05/23/reales
25	The New York Times	opinion the remnants of decades of conflict ar...	Opinion When War Is More Dangerous for Civil...	https://www.nytimes.com/2018/03/07/opinionor
45	The New York Times	footsteps in and around stockholm the secretiv...	In Search of Hilma af Klint, Who Upended Art H...	https://www.nytimes.com/2019/10/21/travel/

Ejemplos para CNBC

	publication	CleanText	title	
12	CNBC	italy s finance minister pier carlo padoan has...	Bailout for Italian banks has been 'absolutely...	https://www.cnbc.com/2016/09/02/we: global-g
49	CNBC	the kremlin said on wednesday it was total non...	Kremlin says it has no compromising dossier on...	https://www.cnbc.com/2017/01/11/kreml says-
146	CNBC	lyft s week is off to a dreary start as the st...	Lyft's stock continues to dive after its disma...	https://www.cnbc.com/2019/04/15/lyf stock-c

Ejemplos para The Hill

	publication	CleanText	title	
2	The Hill	benchmark the venture capital firm that helped...	Uber investor accuses Kalanick of 'undermining...	https://thehill.com/policy/technology/34
11	The Hill	virginia gov terry mcauliffe d included a dig ...	McAuliffe jabs Pence over GOP healthcare bill ...	https://thehill.com/homenews/senate
13	The Hill	former starbucks ceo howard schultz has recrui...	Schultz recruiting GOP insiders ahead of possi...	https://thehill.com/homenews/campaign,

Ejemplos para People

	publication	CleanText	title	url
59	People	nearly 100 000 in jewelry that once belonged t...	Bernie and Ruth Madoff's Antique Jewelry Being...	https://people.com/crime/bernie-and-ruth-madof...
89	People	a doctor s visit is no big deal when you ve go...	Chip Gaines and Son Share Heartwarming Smile a...	https://people.com/parents/joanna-gaines-chip-...
167	People	posh spice still has the moves former pop star...	Victoria Beckham Dances with Cast of Tina: The...	https://people.com/style/watch-victoria-beckha...

Dominios mas frecuentes por medio:

Reuters

	dominio	cantidad
--	---------	----------

0	reuters.com	9431
---	-------------	------

The New York Times

	dominio	cantidad
--	---------	----------

0	nytimes.com	2794
---	-------------	------

1	cn.nytimes.com	9
---	----------------	---

2	learning.blogs.nytimes.com	6
---	----------------------------	---

3	wordplay.blogs.nytimes.com	5
---	----------------------------	---

4	artsbeat.blogs.nytimes.com	5
---	----------------------------	---

CNBC

	dominio	cantidad
--	---------	----------

0	cnbc.com	2623
---	----------	------

The Hill

	dominio	cantidad
--	---------	----------

0	thehill.com	2349
---	-------------	------

People

	dominio	cantidad
--	---------	----------

0	people.com	1528
---	------------	------

Autores mas frecuentes por medio:

Reuters

	autor	cantidad
0	SIN AUTOR	6573
1	Field Level Media	82
2	Nate Raymond	31
3	David Shepardson	31
4	Jonathan Stempel	27
5	Alan Baldwin	19
6	Daniel Wiessner	18
7	Jim Christie	14
8	Lucia Mutikani	13
9	Huw Jones	13

The New York Times

	autor	cantidad
0	SIN AUTOR	237
1	The Associated Press	74
2	The Editorial Board	31
3	The Learning Network	20
4	The New York Times	19
5	Deb Amlen	17
6	Sam Sifton	14
7	Florence Fabricant	13
8	J. D. Biersdorfer	13
9	David Leonhardt	13

CNBC

	autor	cantidad
0	SIN AUTOR	2600
1	Matt Sommer, vice president/director, Retireme...	1
2	Jennifer Fitzgerald, CEO and co-founder of Pol...	1
3	Scott Wong, Amie Parnes, the Hill	1
4	Robert Laszewski, president of Health Policy a...	1
5	Nick Vail, financial advisor at Integrity Weal...	1
6	Richard Nephew, former State Department offici...	1
7	Victoria A. Espinel is president and CEO of BS...	1
8	Ben LaBolt, former Obama spokesman	1
9	Simon Lewis, co-founder of Certo Software	1

The Hill

	autor	cantidad
0	John Bowden	91
1	Rebecca Savransky	68
2	Julia Manchester	57
3	Tal Axelrod	50
4	Jordain Carney	46
5	Joe Concha	43
6	Morgan Gstalter	39
7	Mark Hensch	39
8	Justin Wise	37
9	Jessie Hellmann	36

People

	autor	cantidad
0	Alexia Fernandez	60
1	Dave Quinn	59
2	People Staff	54
3	Stephanie Petit	51
4	Karen Mizoguchi	45
5	Aurelie Corinthios	40
6	Natalie Stone	36
7	Char Adams	36
8	Jen Juneau	35
9	Maria Pasquini	35

Secciones mas frecuentes por medio:

Reuters

	seccion	cantidad
0	World News	1227
1	Market News	1218
2	Business News	1076
3	Financials	679
4	Intel	465
5	Bonds News	415
6	Healthcare	348
7	Sports News	304
8	Consumer Goods and Retail	283
9	Commodities	188

The New York Times

	seccion	cantidad
0	world	329
1	opinion	319
2	us	297
3	arts	239
4	sports	235
5	business	202
6	nyregion	146
7	fashion	90
8	books	86
9	movies	78

CNBC

	seccion	cantidad
0	Wires	733
1	SIN SECCION	485
2	Politics	175
3	Tech	146
4	Markets	64
5	Market Insider	63
6	Investing	50
7	Health and Science	41
8	Retail	37
9	Economy	37

The Hill

	seccion	cantidad
0	SIN SECCION	2349

People

	seccion	cantidad
0	tv	280
1	movies	153
2	style	136
3	crime	130
4	celebrity	112
5	music	100
6	royals	83
7	parents	72
8	pets	67
9	food	60

Comienzos de articulos repetidos mas frecuentes:

	publication	article_start	cantidad
15310	The Hill	View the discussion thread. The Hill 1625 K St...	51
14495	The Hill	President TrumpDonald John TrumpFacebook relea...	38
14505	The Hill	President TrumpDonald John TrumpTrump pushes b...	37
3532	People	PEOPLE Now airs live, Monday through Friday, f...	18
13798	The Hill	Democratic strategist Antjuan Seawright said T...	14
13819	The Hill	Donald TrumpDonald John TrumpPossible GOP chal...	13
14750	The Hill	Senate Majority Leader Mitch McConnellAddison ...	9
14052	The Hill	Hillary ClintonHillary Diane Rodham ClintonTop...	9
14051	The Hill	Hillary ClintonHillary Diane Rodham ClintonLew...	8
14705	The Hill	Sen. Elizabeth WarrenElizabeth Ann WarrenHarry...	8
13663	The Hill	Bernie SandersBernie SandersJoe Biden faces an...	8
17711	The New York Times	Times Insider delivers behind-the-scenes insig...	7
14805	The Hill	Speaker Paul RyanPaul Davis RyanEmbattled Juul...	6
14517	The Hill	President-elect Donald TrumpDonald John TrumpT...	5
3392	People	Lisa Lillien is the author of the popular Hung...	5
17957	The New York Times	What to Cook Sam Sifton emails readers of Cook...	5
15231	The Hill	To view past editions of The Hill's 12:30 Repo...	5
14673	The Hill	Secretary of State Rex TillersonRex Wayne Till...	5
15333	The Hill	Welcome to OVERNIGHT CYBERSECURITY, your daily...	5
15332	The Hill	Welcome to Hillicon Valley, The Hill's newslet...	4

Los datos revelan varias pistas directas de identificación del medio en el texto:

1. Dateline de Reuters (la más fuerte) Casi el 100% de los artículos de Reuters contienen la palabra "reuters" en el cuerpo del texto, debido a la plantilla `LUGAR, Fecha (Reuters) –` que encabeza cada nota. Es una firma estructural que permitiría identificar el medio con una sola regla.

2. URLs El campo `url` contiene el dominio del medio (`reuters.com`, `nytimes.com`, `cnn.com`, etc.), lo que permite identificar el origen con exactitud perfecta. No afecta el texto del artículo, pero sería data leakage si se usara como feature.

3. Nombre del medio en el texto Además de Reuters, The Hill aparece en 2.392 artículos y CNBC en 961. People suma 5.938 menciones, aunque "people" es una palabra muy común en inglés y esas ocurrencias podrían no referir al medio.

4. Plantillas repetidas The Hill tiene artículos con encabezados de newsletter repetidos decenas de veces ("Welcome to Hillicon Valley", "Welcome to OVERNIGHT CYBERSECURITY", "To view past editions of The Hill's 12:30 Report"), y People tiene plantillas del tipo "PEOPLE Now airs live, Monday through Friday". Estos comienzos identifican el medio de forma casi perfecta.

5. Secciones y autores Las secciones son propias de cada medio (The Hill no tiene sección definida en ningún artículo; las secciones de People como "royals" o "pets" son exclusivas de ese medio). Algunos autores también publican exclusivamente en un solo medio.

¿Conviene eliminarlas?

Sí. Si el objetivo es clasificar por estilo o contenido editorial real, mantener estas pistas haría que el clasificador aprenda atajos triviales en lugar de diferencias genuinas de lenguaje o enfoque temático. El modelo tendría alto accuracy pero sin generalización.

Recomendaciones:

- Eliminar el dateline de Reuters con una regex del tipo `^[A-Z ,\d]+ \ (Reuters\ ) [^–]*–\s*`
- No usar las columnas `url`, `section` ni `author` como features
- Eliminar o normalizar los encabezados de newsletter repetidos de The Hill y People
- Evaluar filtrar ocurrencias del nombre exacto del medio en el texto, con cuidado de no eliminar usos legítimos de palabras comunes como "people"

F. Restricción por sección o período temporal

Evalúe si conviene restringir el análisis a artículos de una misma sección temática o de un período temporal acotado, con el objetivo de reducir el efecto del tema sobre una futura tarea de clasificación por medio.

No es necesario implementar esta restricción, pero sí discutir sus posibles ventajas y desventajas.

Restricción por sección temática

La motivación es clara: si Reuters publica mayormente noticias financieras y People publica exclusivamente contenido de celebridades, un clasificador podría aprender a distinguir los medios simplemente por el tema, sin capturar diferencias reales de estilo o vocabulario editorial.

Sin embargo, la restricción por sección presenta problemas prácticos importantes con estos datos:

- **The Hill no tiene sección en ningún artículo** (el campo `section` es `NaN` en los 2.349 artículos). Aplicar un filtro por sección lo excluiría completamente del análisis.
- Las secciones **no son comparables entre medios**: la sección "Business News" de Reuters no equivale a "Markets" de CNBC ni a "business" del NYT. No existe un esquema de secciones compartido.
- El campo `section` tiene un 33.87% de valores faltantes en el dataset general, lo que limita aún más la cobertura.

Una alternativa parcial sería definir secciones temáticas propias (por ejemplo, agrupando por palabras clave del título), pero eso requiere trabajo adicional y decisiones arbitrarias.

Restricción por período temporal

Acotar el análisis a un rango de fechas específico reduce el riesgo de que eventos puntuales dominen el vocabulario de ciertos medios en ciertos momentos. También garantiza que todos los medios estén cubriendo los mismos eventos del mundo.

La desventaja principal es la reducción del tamaño del dataset, que ya es moderado. Además, algunos medios pueden tener cobertura más esparsa en ciertos períodos, generando desbalance entre clases.

Conclusión


Ninguna de las dos restricciones es sencilla de aplicar con estos datos tal como están. La restricción temporal es más viable porque no depende de metadatos inconsistentes, pero implica aceptar menor volumen de datos. La restricción por sección requeriría primero construir una taxonomía temática propia. En la práctica, una estrategia razonable sería combinar ambas parcialmente: seleccionar un período de superposición donde todos los medios tengan cobertura comparable, y monitorear si los temas dominantes varían mucho entre medios dentro de ese período.

Parte 2: Conteo de Palabras y Visualizaciones

A. Palabras más frecuentes por medio

Realice una visualización que permita comparar las palabras más frecuentes de cada uno de los cinco medios de prensa.

Sin necesidad de implementarlo, proponga ideas para modificar esta visualización con el fin de encontrar diferencias entre secciones temáticas, fechas, o tipos de noticias.



Problema encontrado: dominancia de stop words

Las palabras más frecuentes en todos los medios son prácticamente idénticas: artículos, preposiciones y pronombres del inglés ("the", "to", "a", "of", "in", "and", "that", "said", etc.). Estas palabras no aportan información discriminativa entre medios y ocultan las diferencias reales de vocabulario.

Ideas para mejorar la visualización sin implementar:

1. **Eliminar stop words:** filtrar una lista estándar (por ejemplo, la de NLTK o scikit-learn) antes de contar. Esto haría visibles las palabras con contenido semántico real.
2. **Usar TF-IDF en lugar de frecuencia cruda:** ponderar cada palabra por qué tan exclusiva es de un medio respecto al resto. Así se destacarían términos característicos de cada outlet (e.g., "reuters" para Reuters, "trump" para The Hill, nombres de famosos para People) en lugar de palabras universales.
3. **Restringir por sección o fecha:** mostrar el top de palabras solo para un subconjunto de artículos (una sección temática o un período), para ver si el vocabulario distintivo cambia según el contexto.


4. **Comparar títulos vs. cuerpos:** generar la misma visualización separada para `title` y `article`, para ver si el estilo léxico difiere entre ambos campos por medio.

B. Medios con mayor cantidad de palabras

Corra el código que permite encontrar los medios con mayor cantidad de palabras.

En caso de encontrar algún problema luego de realizar la visualización, comente a qué se debe y proponga formas de resolverlo.

	publication	total_palabras	promedio_por_articulo	articulos
0	The New York Times	2630560	926.253521	2840
1	Reuters	2605551	276.275156	9431
2	The Hill	1390327	591.880375	2349
3	CNBC	1254102	478.117423	2623
4	People	644466	421.770942	1528



Problema: el total de palabras está sesgado por el número de artículos

Si se mide solo el total acumulado, Reuters domina ampliamente por volumen (9.431 artículos vs. ~1.500–2.800 de los demás), no necesariamente porque sus artículos sean más extensos. Esto hace que la comparación sea poco informativa sobre el estilo de cada medio.

La métrica más relevante es el **promedio de palabras por artículo**, que permite comparar la extensión típica independientemente del tamaño del dataset. Con esa normalización pueden aparecer diferencias más significativas: por ejemplo, artículos del NYT suelen ser más largos que los de Reuters, y notas de People suelen ser más cortas.

Formas de resolver o complementar:

- Usar el promedio (o mediana, más robusta a outliers) de palabras por artículo como métrica principal.


- Complementar con un boxplot o violinplot para ver la distribución completa, no solo la media, ya que algunos medios pueden tener alta varianza (mezcla de noticias breves y artículos largos).
- Normalizar también por caracteres en lugar de palabras, para evitar que artículos con muchas palabras cortas inflen el conteo.

C. Matriz de menciones entre medios


Construya una matriz de 5×5, donde cada fila y columna corresponden a un medio de prensa, y la entrada (i,j) contiene la cantidad de veces que el medio *i* menciona al medio *j*.

Opcional: genere un grafo dirigido con esa matriz de adyacencia para visualizar las menciones. Puede ser útil la biblioteca `networkx`.

	Reuters	The New York Times	CNBC	The Hill	People
Reuters	8358	29	31	5	1517
The New York Times	45	482	13	37	1599
CNBC	821	46	901	7	812
The Hill	71	127	13	2335	969
People	4	38	3	8	1041



Grafo dirigido de menciones entre medios



Observaciones sobre la matriz de menciones

La columna de **People** está inflada artificialmente: "people" es una palabra extremadamente común, por lo que prácticamente cualquier artículo la contiene. Esto distorsiona tanto la fila (People menciona a otros) como la columna (otros mencionan a People). Para obtener un conteo más preciso habría que buscar la frase exacta con mayúscula o en contextos específicos (e.g., "People magazine", "people.com"). De forma similar podría suceder con **The Hill**, como subcadena en frases como "on the hill", aunque observando la matriz, esto no parece suceder de forma destacable.

La fila de **Reuters** tiende a tener conteos altos en todas las columnas simplemente porque tiene casi cuatro veces más artículos que los demás medios. Para comparar la "propensión" a mencionar otros medios de forma más justa, convendría normalizar por el número de artículos de cada fila (es decir, expresar la entrada (i,j) como fracción de artículos del medio i , en lugar del conteo bruto). Además, como ya observamos anteriormente, **Reuters** usa como plantilla al inicio de sus publicaciones la fecha, el lugar y su propio nombre, lo cual infla aún más este número en la matriz.

A pesar de estas limitaciones, el heatmap y el grafo permiten ver qué medios son más referenciados por otros en términos absolutos, y si existen relaciones

asimétricas (por ejemplo, si The Hill menciona al NYT mucho más de lo que el NYT menciona a The Hill).

D. Preguntas propuestas

Proponga al menos tres preguntas que se podrían intentar responder a partir de estos datos, y mencione posibles caminos para responderlas, sin implementar nada.

1. **¿Qué tan bien se puede adivinar el medio de prensa solo leyendo el texto?**

Camino posible: armar un conjunto de entrenamiento y prueba a partir de `CleanText` (o título + cuerpo), vectorizar con bolsa de palabras o TF-IDF, y probar un clasificador simple (por ejemplo regresión logística o Naive Bayes). Comparar accuracy usando solo título, solo cuerpo, o ambos.

2. **¿Los medios cubren los mismos temas al mismo tiempo o cada uno tiene "olas" distintas?**

Camino posible: agrupar artículos por mes o por año, y para cada medio contar frecuencias de palabras o de la columna `section` (donde no falte). Graficar series temporales o mapas de calor medio × tiempo para ver si hay picos comunes (crisis, elecciones) o picos propios de un solo outlet.

3. **¿Qué tan "parecidos" son dos medios en el vocabulario que usan?**

Camino posible: a partir de los conteos de palabras por medio, medir similitud entre vectores de frecuencias o TF-IDF (por ejemplo coseno entre medios). Interpretar qué pares quedan más cerca y si coincide con el tipo de noticia (economía, política, espectáculos, etc.).